

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI  
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

# Praca dyplomowa inżynierska

na kierunku Informatyka  
w specjalności Inżynieria Systemów Informatycznych

Przeglądarka danych uzyskanych z sekwencjonowania następnej  
generacji (NGS)

Tomasz Kogowski

Numer albumu 261428

promotor  
dr inż. Tomasz Gambin

Warszawa 2017

## **Streszczenie**

## **Abstract**



„załącznik nr 3 do zarządzenia nr 24/2016 Rektora PW

.....  
miejscowość i data

.....  
imię i nazwisko studenta

.....  
numer albumu

.....  
kierunek studiów

### OŚWIADCZENIE

Świadomy/-a odpowiedzialności karnej za składanie fałszywych zeznań oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie, pod opieką kierującego pracą dyplomową.

Jednocześnie oświadczam, że:

- niniejsza praca dyplomowa nie narusza praw autorskich w rozumieniu ustawy z dnia 4 lutego 1994 roku o prawie autorskim i prawach pokrewnych (Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.) oraz dóbr osobistych chronionych prawem cywilnym,
- niniejsza praca dyplomowa nie zawiera danych i informacji, które uzyskałem/-am w sposób niedozwolony,
- niniejsza praca dyplomowa nie była wcześniej podstawą żadnej innej urzędowej procedury związanej z nadawaniem dyplomów lub tytułów zawodowych,
- wszystkie informacje umieszczone w niniejszej pracy, uzyskane ze źródeł pisanych i elektronicznych, zostały udokumentowane w wykazie literatury odpowiednimi odnośnikami,
- znam regulacje prawne Politechniki Warszawskiej w sprawie zarządzania prawami autorskimi i prawami pokrewnymi, prawami własności przemysłowej oraz zasadami komercjalizacji.

Oświadczam, że treść pracy dyplomowej w wersji drukowanej, treść pracy dyplomowej zawartej na nośniku elektronicznym (płycie kompaktowej) oraz treść pracy dyplomowej w module APD systemu USOS są identyczne.

.....  
czytelny podpis studenta”

# Spis treści

<b>1 Wstęp</b>	<b>6</b>
1.1 Motywacja . . . . .	6
1.2 Cel pracy . . . . .	6
<b>2 Podstawy teoretyczne</b>	<b>7</b>
<b>3 Wymagania funkcjonalne i нефункционалне</b>	<b>8</b>
<b>4 Istniejące rozwiązania</b>	<b>9</b>
<b>5 Wybór technologii</b>	<b>10</b>
5.1 Język programowania Scala . . . . .	10
5.2 System zarządzania bazą danych . . . . .	10
5.2.1 MySQL . . . . .	11
5.2.2 SQLite . . . . .	11
5.2.3 PostgreSQL . . . . .	11
5.2.4 Uzasadnienie wyboru PostgreSQL . . . . .	12
5.3 Slick . . . . .	12
5.4 Platforma programistyczna Play . . . . .	12
<b>6 Przypadki użycia</b>	<b>13</b>
6.1 Autoryzacja . . . . .	13
6.1.1 Role . . . . .	13
6.1.2 Rejestracja użytkownika . . . . .	13
6.1.3 Logowanie użytkownika . . . . .	13
6.2 Przeglądanie danych z sekwencjonowania DNA . . . . .	13
6.2.1 Widok listy dostępnych próbek . . . . .	13
6.2.2 Ekran dostępnych genomów . . . . .	13
6.2.3 Filtrowanie danych . . . . .	13
6.3 Panel administratora . . . . .	13
6.3.1 Zarządzanie filtrami . . . . .	13
6.3.2 Zarządzanie rolami użytkowników . . . . .	13
6.3.3 Zarządzanie widocznością próbek dla użytkowników . . . . .	13
<b>7 Schemat bazy danych</b>	<b>14</b>

<b>8</b>	<b>Opis implementacji</b>	<b>15</b>
<b>9</b>	<b>Bezpieczeństwo aplikacji</b>	<b>16</b>
9.1	Niebezpieczeństwa . . . . .	16
9.2	Wykorzystanie protokołu https . . . . .	16
<b>10</b>	<b>Testy oraz wydajność</b>	<b>17</b>
<b>11</b>	<b>Wnioski i podsumowania</b>	<b>18</b>
	<b>Literatura</b>	<b>18</b>

# **1 Wstęp**

## **1.1 Motywacja**

## **1.2 Cel pracy**

## **2 Podstawy teoretyczne**

*Czy jest sens pisać o tym? 1-2 strony o tym czym jest DNA, genomu, kodony, jak zmiana w DNA może wpływać na organizm i dlaczego warto zajmować się badaniem DNA*



### **3 Wymagania funkcjonalne i нефункционалне**

*Opisanie o wymaganiu dostępu do próbek oraz transkryptów, filtracji, zapisywaniu wyboru filtrów, wyboru widocznych kolumn, sortowania, filtrowania pobranych już danych.*

*Parę wymagań нефункционалных jak dostęp wielu użytkowników na raz, czas odpowiedzi itp.*

## 4 Istniejące rozwiązania

Exac broad institute, Exac Harvard Skupić się na tym iż systemy nie pozwalają na personalizację interfejsu dla użytkownika. Harvard udostępnia REST API nieprzyjazne użytkownikowi

**Czy dodać tu zdjęcia z tych aplikacji?**

## 5 Wybór technologii

Platforma klastrowego przetwarzania danych - Apache Spark[2], z którą współpracować będzie aplikacja, została stworzona oraz udostępnia interfejs programistyczny w języku Scala. Naturalnym przez to wydało się wybranie tego języka programowania do stworzenia przeglądarki danych.

### 5.1 Język programowania Scala

W aplikacji użyto języka Scala w wersji 2.11.7 [1]. Jest to język programowania powstały w 2001 roku pod kierownictwem Martina Odersky'ego w Lozannie. Działa na Wirtualnej Maszynie Javy a do 2012 roku wspierała platformę .NET opracowaną przez firmę Microsoft. Język ten nadaje się równie dobrze do krótkich, zwartych skryptów wywoływanych podobnie do skryptów języka Python jak i do tworzenia wydajnych, ogromnych, bezpiecznych systemów sieciowych.

Jest językiem łączącym cechy języków funkcyjnych oraz obiektowych. Nie jest jednak obligatoryjny funkcyjny styl programowania, do którego nie jest przyzwyczajona większość programistów. Scala w swoim założeniu nawiązuje do minimalizmu składni Lispa to znaczy że nie opiera się na składni a na funkcjach bibliotecznych. Nazwa ma podkreślić skalowalność języka, dzieje się tak dzięki możliwości tworzenia dodatkowych typów i struktur wyglądających jak nowa składnia języka. Zaletą języka jest również to że dzięki kompatybilności z językiem Java mamy możliwość wykorzystania każdej linii kodu napisanej w owym języku.

### 5.2 System zarządzania bazą danych

Zadanie stworzenia bazy danych przechowującej informacje konfiguracyjne, dane użytkowników oraz o użytkownikach było dużą częścią tworzenia systemu i wymagało wybrania odpowiedniego systemu zarządzania bazą danych. Model bazodanowy został zaprojektowany w modelu opartym na relacyjnej organizacji danych, przez co wybór ograniczył się do darmowych technologii realizujących relacyjne bazy danych.

Biorąc pod uwagę powyższe kryteria, można porównać najpopularniejsze systemami, są nimi[3]:

- MySQL
- SQLite
- PostgreSQL

### **5.2.1 MySQL**

#### **Zalety**

- proste i łatwe w obsłudze
- wysoki poziom bezpieczeństwa

#### **Wady**

- nie realizuje w pełni standardu SQL
- problematyczny jednoczesny zapis i odczyt

### **5.2.2 SQLite**

#### **Zalety**

- zgodny ze standardem SQL
- przenośny dzięki oparciu bazy o jeden plik

#### **Wady**

- brak zarządzania użytkownikami i dostępami do danych

### **5.2.3 PostgreSQL**

#### **Zalety**

- zgodny ze standardem SQL
- wsparcie dla współbieżności
- pełne wsparcie dla transakcji

## **Wady**

- słaba wydajność
- trudność instalacji dla początkujących użytkowników

### **5.2.4 Uzasadnienie wyboru PostgreSQL**

Po analizie ostateczny wybór systemem padł na PostgreSQL. To otwarte i darmowe oprogramowanie posiada bardzo dużą społeczność, której wiedza jest łatwo dostępna w internecie i posiada wiele narzędzi i bibliotek przeznaczonych do pracy z owym systemem. Istotny wpływ na decyzję miała również łatwość integracji PostgreSQL na inne systemy.

## **5.3 Slick**

Pracę z bazą danych po stronie serwera aplikacyjnego znacznie ułatwia oprogramowanie pozwalające na odwzorowanie obiektowo-relacyjne tabel bazodanowych na obiekty języka programowania. Dzięki tej technice programista może traktować obiekty bazodanowe jak elementy kolekcji czy pola obiektów.

Takim narzędziem jest stworzone przez firmę Lightbend, Inc. oprogramowanie Slick[4] pozwalające na pełną kontrolę nad bazą danych oraz pisanie klasycznych zapytań SQL.

## **5.4 Platforma programistyczna Play**

*zalety i wady, trochę więcej o aplikacjach przeglądarkowych i dlaczego z tej technologii chcemy korzystać*

## **6 Przypadki użycia**

*Opis każdej funkcjonalności oraz zdjęcia. Czy skupić się bardziej na opisie działania aplikacji czy raczej implementacji?*

### **6.1 Autoryzacja**

#### **6.1.1 Role**

#### **6.1.2 Rejestracja użytkownika**

#### **6.1.3 Logowanie użytkownika**

### **6.2 Przeglądanie danych z sekwencjonowania DNA**

#### **6.2.1 Widok listy dostępnych próbek**

#### **6.2.2 Ekran dostępnych genomów**

#### **6.2.3 Filtrowanie danych**

### **6.3 Panel administratora**

#### **6.3.1 Zarządzanie filtrami**

#### **6.3.2 Zarządzanie rolami użytkowników**

#### **6.3.3 Zarządzanie widocznością próbek dla użytkowników**

## 7 Schemat bazy danych

Schemat jest bardzo duży, może załączyć w częściach w dodatku i odsyłać tam czytelnika?

## 8 Opis implementacji

Czy nie połączyć opisu implementacji razem z przypadkami użycia? Kolejno opisując użycie aplikacji mógłbym opisać jak to się odbywa w kodzie.



## **9 Bezpieczeństwo aplikacji**

### **9.1 Niebezpieczeństwa**

### **9.2 Wykorzystanie protokołu https**

*Opisać jak od strony bardziej technicznej odbywa się zabezpieczanie haseł użytkownika (sól, sha512)*

## **10 Testy oraz wydajność**

## **11 Wnioski i podsumowania**

## Literatura

- [1] École Polytechnique Fédérale - Scala documentation, Available at: <http://docs.scala-lang.org/> (Accessed: 10 August 2017).
- [2] The Apache Software Foundation - Apache Spark Available at: <https://spark.apache.org/> (Accessed: 10 August 2017).
- [3] Hostovita sp. z o.o. - Porównanie relacyjnych SZBD: SQLite, MySQL, PostgreSQL Available at: <https://hostovita.pl/blog/porownanie-relacyjnych-systemow-zarzadzania-bazami-danych-sqlite-mysql-postgresql/> (Accessed: 10 August 2017).
- [4] Lightbend, Inc Slick documentation. Available at: <http://slick.lightbend.com/docs/> (Accessed: 10 August 2017).

## **Wykaz rysunków i tabel**